

COMP9414: 人工智能第5a讲：不

确定性

韦恩-沃布克

电邮：w. wobcke@unsw.edu.au

用不确定性进行推理

- 代理人并不总是能够确定所有命题的真实性，因此可能不仅有 "平白无故" 的信念 (P 或 $\neg P$)。
- 由于不可预测性或非确定性，一些环境本身对代理人产生了不确定性，所以命题对这些环境的建模是不充分的。

本讲座

- 不确定性
- 概率论
- 条件概率和贝叶斯法则
- 贝叶斯网络
 - ▲ 贝叶斯网络的语义学
 - ▲ 贝叶斯网络中的推理

逻辑方法的问题

- 代理人的理性决策需要在目标的重要性和实现目标的可能性，以及行动和不实现目标的成本之间进行权衡。

-
- 考虑尝试将医疗诊断系统正规化

$$p \forall (\text{Symptom}(p, \text{AbdominalPain}) \rightarrow \text{Disease}(p, \text{Appendicitis}))$$

- 这一规则是不正确的，因为腹痛的病人可能患有其他疾病。

$$p \forall (\text{Symptom}(p, \text{AbdominalPain}) \rightarrow$$

$$\text{疾病}(p, \text{阑尾炎}) \vee \text{疾病}(p, \text{溃疡}) \vee \text{疾病}(p, \text{印第安}) \dots)$$

- 因果规则如何？

$$p \forall (\text{Disease}(p, \text{Ulcer}) \rightarrow \text{Symptom}(p, \text{AbdominalPain}))$$

不确定性的来源

- 由于不完全性，逻辑方法会出现困难：代理人可能没有完整的领域理论 无知：代理人可能没有足够的领域信息
噪声：代理人拥有的信息可能不可靠
非确定性：环境本身可能是随机的
不可预测性：环境可能是固有的不可预测的
- 概率给出了一种总结这种不确定性的方法
▲
例如，代理人认为，如果病人有腹痛，患阑尾炎的概率为0.75。

样品空间和活动

- 抛掷三次硬币
- 可能的结果是

タイトTTH THT THH
HTT HTH HHT HHH
- 所有可能结果的集合 $s=\{ttt, tth, tht, thh, htt, hth, hht, hhh\}$ 。
- 样本空间的任何子集被称为事件
- 样本空间的任何单子集被称为简单事件

这些数字意味着什么？


- 统计学/常识分子观点
一组 "事件 "的长距离频率，例如，抛硬币时出现 "头 "的事件的概率=抛硬币时出现 "头 "的长距离频率
- 客观看法
概率是世界的真实方面--客观的
- 个人/主观/贝叶斯观点
基于代理人的知识对命题的信念的衡量，例如，人头的概率是基于对硬币的信念而相信硬币会落在人头上的程度，也可

样品空间和活动

能
只
是
一
种
猜
测
；
不
同
的

代理人可能会分
配不同的概率--
主观的。

简单事件



之前的概率

- $P(A)$ 是一个事件 A 发生的先验或无条件的概率
- 例如, $P(\text{阑尾炎}) = 0.3$
- 在没有任何其他信息的情况下, 代理人认为病人患有阑尾炎的概率为0.3 (30%)。
- 为了说明新信息对概率的影响, 代理人必须用条件概率进行推理以更新概率

概率论的公理

1. $0 \leq P(A) \leq 1$
 - 所有的概率都在0和1之间
2. $P(\text{真})=1$ $P(\text{False}) = 0$
 - 有效命题的概率是1
 - 不能满足的命题的概率为0
3. $p(a \vee b) = p(a) + p(b) - p(a \wedge b)$
 - 可以确定所有其他命题的概率
 - 例如, $P(A \vee \neg A) = P(A) + P(\neg A) - P(A \wedge \neg A)$
 $P(\text{True}) = P(A) + P(\neg A) - P(\text{False})$
 $1 = p(a) + p(\neg a) - 0$
 因此, $P(\neg A) = 1 - P(A)$ 。

随机变量

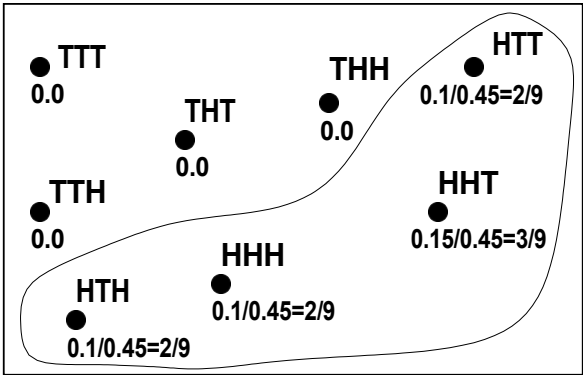
- 命题是随机变量, 可以有几个值
 $P(\text{天气=晴天}) = 0.8$ $P(\text{天气=雨天}) = 0.1$ $P(\text{天气=阴天}) = 0.09$ $P(\text{天气=雪天}) = 0.01$
- 每个随机变量 X 都有一个可能的值域
 (x_1, x_2, \dots, x_n)
- 所有可能值的概率 $P(\text{Weather}) = (0.8, 0.1, 0.09, 0.01)$ 是一个概率分布
- $P(\text{Weather}, \text{Appendicitis})$ 是随机变量的组合, 由交叉乘积表示(也可以

条件概率

- 需要根据新的信息来更新概率
- 使用条件或后验概率
 $P(A|B)$ 是指在我们只知道 B 的情况下, A 的概率。
 例如, $P(\text{阑尾炎}|\text{腹痛}) = 0.75$
- 定义。 $P(A|B) = \frac{P(A \wedge B)}{P(B)}$ 前提是 $P(B) > 0$
- 产品规则。 $P(A \wedge B) = P(A|B) \cdot P(B)$
- $P(X|Y) = P(X = x_i | Y = y_j)$ 对于所有的 i, j
 用逻辑连接词 $P(A \wedge B)$ 来表示复合事件)

$P(x,y) = P(x|y) \cdot P(y)$ --一组方程

正常化



■ 鉴于第一枚硬币是H的条件概率分布

联合概率 分布

- 简单的事件是相互排斥和共同穷尽的
- 复杂事件的概率是兼容的简单事件的概率之和
$$P(\text{阑尾炎}) = 0.04 + 0.06 = 0.10$$
$$P(\text{Appendicitis} \vee \text{AbdominalPain}) = 0.04 + 0.06 + 0.01 = 0.11$$
$$P(\text{Appendicitis}|\text{AbdominalPain}) = \frac{P(\text{Appendicitis} \wedge \text{AbdominalPain})}{P(\text{腹痛})} = \frac{0.04}{0.04+0.01} = 0.8$$
- 问题：在许多变量中，概率的数量是巨大的

联合概率分布

- 对领域内所有事件的概率的完整说明
- 假设随机变量 X_1, X_2, \dots, X_n
- 一个原子（简单）事件是对所有变量的赋值
- 联合概率分布 $P(X_1, X_2, \dots, X_n)$ 为所有可能的原子事件分配概率
- 具有两个布尔随机变量的简单医疗领域

	腹痛	¬腹痛
阑尾炎	0.04	0.06
¬阑尾炎	0.01	0.89

联合概率分布

假设在三个随机变量牙痛、蛀牙和接球上有一些潜在的联合概率分布，我们可以用表格的形式写出来

	牙痛		牙痛	
	接住	接住	接住	接住
空腔	.108	.012	.072	.008
空腔	.016	.064	.144	.576

请注意，表中的条目之和为1.0。
对于任何命题，将其为真的原子事件相加

枚举推理的例子

	牙痛		牙痛	
	接住	接住	接住	接住
空腔	.108	.012	.072	.008
空腔	.016	.064	.144	.576

对于任何一个命题，将其为真的原子事件相加。
 $P(\text{牙痛}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$

枚举的条件概率

	牙痛		牙痛	
	接住	接住	接住	接住
空腔	.108	.012	.072	.008
空腔	.016	.064	.144	.576

$$P(\neg \text{蛀牙} | \text{牙痛}) = \frac{P(\neg \text{蛀牙} \wedge \text{牙痛})}{P(\text{牙痛})} = \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

枚举推理的例子

	牙痛		牙痛	
	接住	接住	接住	接住
空腔	.108	.012	.072	.008
空腔	.016	.064	.144	.576

对于任何一个命题，将其为真的原子事件相加。
 $P(\text{蛀牙} \vee \text{牙痛}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$

贝叶斯法则

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

- 人工智能系统放弃了联合概率，直接使用贝叶斯法则的条件概率工作
- 推导出贝叶斯规则。
 $p(a \wedge b) = p(a|b)p(b)$ (定义)
 $p(b \wedge a) = p(b|a)p(a)$ (定义)
所以 $P(A|B)P(B) = P(B|A)P(A)$ 因为 $P(A \wedge B) = P(B \wedge A)$
因此，如果 $P(A) \neq 0$ 则 $P(B|A) = \frac{P(A|B)P(B)}{P(A)}$

■ 注 : 如果 $P(A)=0$, 则 $P(B|A)$ 是未定义的。

应用贝叶斯规则

- 例子(Russell & Norvig, 1995)

- 医生知道

- 脑膜炎有50%的时间会导致脖子僵硬
- 病人患脑膜炎的机会是 $\frac{1}{50000}$
- 病人出现颈部僵硬的机会是 $\frac{1}{20}$

$$\begin{aligned}
 P(\text{StiffNeck}|\text{Meningitis}) &= 0.5 \\
 P(\text{脑膜炎}) &= \frac{1}{50000} \\
 P(\text{StiffNeck}) &= \frac{1}{20} \\
 P(\text{Meningitis}|\text{StiffNeck}) &= \frac{P(\text{StiffNeck}|\text{Meningitis}) \cdot P(\text{脑膜炎})}{P(\text{StiffNeck})} \\
 &= 0.5 \cdot \frac{1}{50000} \cdot \frac{1}{\frac{1}{20}} = 0.0002
 \end{aligned}$$

使用贝叶斯法则

- 假设阑尾炎有两个条件概率

$$P(\text{Appendicitis}|\text{AbdominalPain}) = 0.8$$

$$P(\text{Appendicitis}|\text{Nausea}) = 0.1$$

- $P(\text{Appendicitis}|\text{AbdominalPain} \wedge \text{Nausea})$
 $\frac{P(\text{AbdominalPain} \wedge \text{Nausea}|\text{Appendicitis}) \cdot P(\text{阑尾炎})}{P(\text{腹痛} \wedge \text{恶心})}$

$$P(\text{腹痛} \wedge \text{恶心})$$

- 需要知道 $P(\text{AbdominalPain} \wedge \text{Nausea}|\text{Appendicitis})$

- 对于许多症状来说，这是一项艰巨的任务.....。

正常化

- 避免对症状进行评估

$$P(\text{Meningitis}|\text{StiffNeck}) = \frac{P(\text{StiffNeck}|\text{Meningitis}) \cdot P(\text{脑膜炎})}{P(\text{StiffNeck})}$$

$$P(\neg \text{脑膜炎}|\text{僵硬颈椎}) = \frac{P(\text{僵硬颈椎}|\neg \text{脑膜炎}) \cdot P(\neg \text{脑膜炎})}{P(\text{StiffNeck})}$$

- $P(\text{StiffNeck}) = P(\text{StiffNeck}|\text{Meningitis}) \cdot P(\text{脑膜炎})$
 $+ P(\text{StiffNeck}|\neg \text{Meningitis}) \cdot P(\neg \text{脑膜炎})$

- 所以 $P(\text{脑膜炎}|\text{硬颈}) =$
 $\frac{P(\text{StiffNeck}|\text{Meningitis}) \cdot P(\text{脑膜炎})}{P(\text{StiffNeck}|\text{Meningitis}) \cdot P(\text{Meningitis}) + P(\text{StiffNeck}|\neg \text{Meningitis}) \cdot P(\neg \text{脑膜炎})}$

同样，对于 $P(\neg \text{脑膜炎}|\text{颈椎病})$ 也是如此。

- 因此，从这两个 $P(\text{StiffNeck}|\text{---})$ 可以推导出 $P(\text{StiffNeck})$

有条件的独立

而分母是一个归一化系数

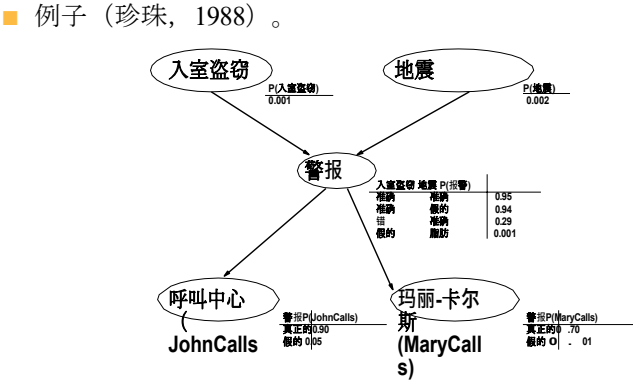
-
- 阑尾炎是导致腹痛和恶心的直接原因
 - **如果**我们知道一个病人患有阑尾炎，恶心的概率不应该取决于腹痛的存在；同样，腹痛的概率也不应该取决于恶心。
 - 鉴于阑尾炎，恶心和腹痛是**有条件地独立存在的**
 - 如果知道 Y 不影响 X 的条件概率，那么事件 X 是**独立于**事件 Y 的，以背景知识 K 为条件。

$$p(x | k) = p(x | y, k)$$

贝叶斯网络

- 贝叶斯网络（也是贝叶斯信念网络、概率网络、因果网络、知识地图）是一个有向无环图（DAG），其中
 - ▲ 每个节点对应于一个随机变量
- 有向链接连接成对的节点--一个来自节点的有向链接
 - X 到节点 Y 意味着 X 对 Y 有直接影响
- ▲ 每个节点都有一个条件概率表，量化了父母对节点的影响
- 贝叶斯网络的独立假设
 - ▲ 每个随机变量都是（有条件地）独立于其非后代的，因为它的父母都是独立的。

贝叶斯网络



- 概率概括了潜在的无限可能的情况。

贝叶斯网络

- 例子（珍珠，1988）。
- 你家里有一个新的防盗报警器，在探测小偷方面相当可靠，但有时也可能对地震作出反应。你还有两个邻居，约翰和玛丽，他们承诺在听到警报时给你打电话。约翰总是在他听到了警报，但有时会把电话铃声和警报混淆起来，然后再打电话，另外，玛丽喜欢大声的音乐，有时会错过警报。考虑到谁打过或没打过电话的证据，我们想估计一下发生入室盗窃的概率。

条件概率表

- 行中包含每个节点值在条件情况下的条件概率（父节点值的可能组合）。

		P(警报 入室盗窃∧地震)	
入室盗窃	地震	准确	错
真	真	0.950	0.050
真	假的	0.940	0.060
假的	真	0.290	0.710
假的	假的	0.001	0.999

贝叶斯网络的语义学

- 贝叶斯网络提供了对领域的完整描述
- 联合概率分布可以从网络中确定
 - △ $P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{Parents}(X_i))$
- 例如, $P(J \wedge M \wedge A \wedge \neg B \wedge \neg E) =$
 $P(J|A).P(M|A).P(A|\neg B \wedge \neg E).P(\neg B).P(\neg E) =$
 $0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 =$
 0.000628
- 贝叶斯网络是一个完整的、非冗余的领域表示（可以比联合概率分布紧凑得多）。

贝叶斯网络的语义学

- 联合概率分布的因子化
- 连锁规则。使用条件概率来分解连接词
 - $P(X_1 \wedge X_2 \wedge \dots \wedge X_n) = P(X_1) \cdot P(X_2 | X_1) \cdot P(X_3 | X_1 \wedge X_2) \cdot \dots \cdot P(X_n | X_1 \wedge \dots \wedge X_{n-1})$
- 现在, 在贝叶斯网络中对变量 X_1, X_2, \dots, X_n 进行排序, 使一个变量排在其父母之后--让 π_{X_i} 是变量 X_i 的父母的元组（这是一个复杂随机变量）。
使用连锁规则, $P(X_1 \wedge X_2 \wedge \dots \wedge X_n) = P(X_1) \cdot P(X_2 | X_1) \cdot P(X_3 | X_1 \wedge X_2) \cdot \dots \cdot P(X_n | X_1 \wedge X_2 \wedge \dots \wedge X_{n-1})$

贝叶斯网络的语义学

- 每个 $P(X_i | X_1 \wedge X_2 \wedge \dots \wedge X_{i-1})$ 的特性是它不是以 X 的一个后代为条件 i （考虑到贝叶斯网络中变量的排序）
- 因此, 根据条件独立性
 - △ $P(X_i | X_1 \wedge X_2 \wedge \dots \wedge X_{i-1}) = P(X_i | \pi_{X_i})$
- 重写给出了连锁规则
 - △ $p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(X_i | \pi_{X_i})$

使用贝叶斯网络进行计算

- 事实1：考虑随机变量 X 的父代 Y_1, Y_2, \dots, Y_n $P(X | Y_1 \wedge \dots \wedge Y_n \wedge Z) = P(X | Y_1 \wedge \dots \wedge Y_n)$
如果 Z 不涉及 X 的后代(包括 X 本身)
- 事实2：如果 Y_1, \dots, Y_n 是成对不相交的, 并穷尽所有的可能性
 - $P(x) = \text{op}(x \wedge y_i) = \text{op}(x | y_i) \cdot P(Y_i)$
 - $p(x | z) = \text{op}(x \wedge y_i | z)$
 - △ 例如, $P(J|B) = \frac{P(J \wedge B)}{P(B)} = \frac{\sum P(J \wedge B \wedge e \wedge a \wedge m)}{P(B)}$, 其中 j 的范围为 $J, \neg J$ 。

$$\frac{P(B)}{\Sigma P(j \wedge B \wedge e \wedge a \wedge m)}$$
$$e \text{代表} E, \neg E, a \text{代表} A, \neg A \text{和} m \text{代表} M, \neg M$$

使用贝叶斯网络进行计算

- $P(J \wedge B \wedge E \wedge A \wedge M) = P(J|A) \cdot P(B) \cdot P(E) \cdot P(A|B \wedge E) \cdot P(M|A) =$
 $0.90 \times 0.001 \times 0.002 \times 0.95 \times 0.70 =$
 0.000001197
- $p(j \wedge b \wedge \neg e \wedge a \wedge m) = 0.0005910156$
- $p(j \wedge b \wedge e \wedge \neg a \wedge m) = 5 \times 10^{-11}$
- $p(j \wedge b \wedge e \wedge \neg a \wedge \neg m) = 2.99 \times 10^{-8}$
- $p(j \wedge b \wedge e \wedge a \wedge \neg m) = 0.000000513$
- $p(j \wedge b \wedge \neg e \wedge a \wedge m) = 0.000253292$
- $p(j \wedge b \wedge e \wedge \neg a \wedge \neg m) = 4.95 \times 10^{-9}$
- $p(j \wedge b \wedge \neg e \wedge \neg a \wedge \neg m) = 2.96406 \times 10^{-6}$

使用贝叶斯网络进行计算

- 因此, $P(J|B) = \frac{P(J \wedge B)}{P(B)} = \frac{\sum P(J \wedge B \wedge e \wedge a \wedge m)}{\sum P(j \wedge b \wedge e \wedge a \wedge m)} = \frac{0.00849017}{0.001}$
- $p(j|b) = 0.849017$
- 通常可以简化计算, 而不使用完整的联合概率--
但并非总是如此

使用贝叶斯网络进行计算

- $p(\neg j \wedge b \wedge e \wedge a \wedge m) = 0.000000133$
- $p(\neg j \wedge b \wedge \neg e \wedge a \wedge m) = 6.56684 \times 10^{-5}$
- $p(\neg j \wedge b \wedge e \wedge \neg a \wedge m) = 9.5 \times 10^{-10}$
- $p(\neg j \wedge b \wedge \neg e \wedge \neg a \wedge m) = 5.6886 \times 10^{-7}$
- $p(\neg j \wedge b \wedge e \wedge a \wedge \neg m) = 0.000000057$
- $p(\neg j \wedge b \wedge \neg e \wedge a \wedge \neg m) = 2.81436 \times 10^{-5}$
- $p(\neg j \wedge b \wedge e \wedge \neg a \wedge \neg m) = 9.405 \times 10^{-8}$
- $p(\neg j \wedge b \wedge \neg e \wedge \neg a \wedge \neg m) = 5.63171 \times 10^{-5}$

贝叶斯网络的推理

诊断性推理。从效果到原因

$$P(\text{Burglary} | \text{JohnCalls}) = 0.016$$

因果推理。从原因到结果

$$P(\text{JohnCalls} | \text{Burglary}) = 0.85 ; P(\text{MaryCalls} | \text{Burglary}) = 0.67$$

因果推理。解释了

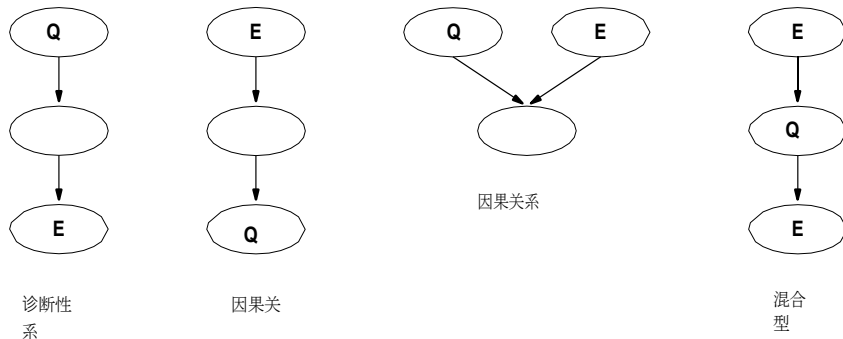
$$P(\text{Burglary} | \text{Alarm}) = 0.3736, \text{ 但加上证据, } P(\text{Burglary} | \text{Alarm} \wedge \text{Earthquake}) = 0.003 ; \text{ 尽管入室盗窃和地震是独立的, 但一个的存在使另一个的可能性大大降低}$$

混合推理。上述模式的组合 诊断+因果。 $P(\text{Alarm} | \text{JohnCalls})$

$\neg \text{Earthquake}$)

因果关系+诊断性 $\circ P(\text{Burglary} | \text{JohnCalls} \wedge \neg \text{Earthquake})$

贝叶斯网络的推理



- Q =询问； E =证据

例子 - 诊断性推断

- $P(\text{Earthquake}|\text{Alarm})$
- $$P(E|A) = \frac{P(A|E) \cdot P(E)}{P(A)}$$

$$= \frac{P(A|B \wedge E) \cdot P(B) \cdot P(E) + P(A|\neg B \wedge E) \cdot P(\neg B) \cdot P(E)}{P(A)}$$

$$= \frac{0.95 \times 0.001 \times 0.002 + 0.29 \times 0.999 \times 0.002}{5.8132 \times 10^{-4}} = 0.2310087$$
- 现在 $P(A) = P(A|B \wedge E) \cdot P(B) \cdot P(E) + P(A|\neg B \wedge E) \cdot P(\neg B) \cdot P(E) + P(A|B \wedge \neg E) \cdot P(B) \cdot P(\neg E) + P(A|\neg B \wedge \neg E) \cdot P(\neg B) \cdot P(\neg E)$
而 $P(A|B \wedge \neg E) \cdot P(B) \cdot P(\neg E) + P(A|\neg B \wedge \neg E) \cdot P(\neg B) \cdot P(\neg E)$
所以 $P(A) = 5.8132 \times 10^{-4} + 0.001935122 = 0.002516442$
- 因此, $P(E|A) = \frac{5.8132 \times 10^{-4}}{0.002516442} = 0.2310087$
- 事实4: $P(X \wedge Y) = P(X)$ 。如果 X, Y 是独立的, 则 $P(Y)$ 。

例子 - 因果推理

- $P(\text{JohnCalls}|\text{Burglary})$
- $$p(j|b) = p(j|a \wedge b) \cdot P(a|b) + p(j|\neg a \wedge b) \cdot P(\neg a|b)$$

$$= P(J|A) \cdot P(A|B) + P(J|\neg A) \cdot P(\neg A|B)$$

$$= P(J|A) \cdot P(A|B) + P(J|\neg A) \cdot (1 - P(A|B))$$
- 现在 $P(A|B) = P(A|B \wedge E) \cdot P(E|B) + P(A|B \wedge \neg E) \cdot P(\neg E|B)$

$$= P(A|B \wedge E) \cdot P(E) + P(A|B \wedge \neg E) \cdot P(\neg E)$$

$$= 0.95 \times 0.002 + 0.94 \times 0.998 = 0.94002$$
- 因此, $P(J|B) = 0.90 \times 0.94002 + 0.05 \times 0.05998 = 0.849017$
- 事实3: $P(X|Z) = P(X|Y \wedge Z) \cdot P(Y|Z) + P(X|\neg Y \wedge Z) \cdot P(\neg Y|Z)$

总结

$|Z)$, 因为
 $X \wedge Z \equiv (X \wedge Y \wedge Z) \vee (X \wedge \neg Y \wedge Z)$ (事实2的条件版本)

-
- 由于噪音或不确定性，用概率来推理是很有用的
 - 由于有大量的数值，用联合概率分布进行计算很困难
-

- 使用贝叶斯法则和独立假设可以简化推理过程
 - 贝叶斯网络允许紧凑地表示概率和有效地进行概率推理
 - 可以给出优雅的递归算法，使贝叶斯网络的推理过程自动化
-